

Detecția Automată a Fracturilor Osoase din Imagini Radiografice Folosind Arhitectura YOLOv8s

Onofreiciuc Ioana Alexandra
Facultatea de Matematică și Informatică
Universitatea din București
ioana-alexandra.onofreiciuc@s.unibuc.ro

Rezumat—Diagnosticarea fracturilor osoase din radiografii este un proces care poate avea erori de interpretare. Această lucrare descrie un sistem automat de detecție și localizare a fracturilor bazat pe arhitectura YOLOv8s, care poate să identifice șapte tipuri distincte de leziuni ale membrului superior: *elbow positive*, *fingers positive*, *forearm fracture*, *humerus fracture*, *humerus*, *shoulder fracture* și *wrist positive*. Scorul maxim obținut este $mAP@0.5 = 0.266$, cu o precizie de 0.249 și un recall de 0.327 după 20 de epoci de antrenament. Pentru a testa a modelul a fost dezvoltată o aplicație web folosind Streamlit. Rezultatele arată că tehnicile moderne de deep learning pot contribui semnificativ la diagnosticul medical.

Index Terms—fracturi osoase, radiografie, detecție obiecte, rețele neuronale convoluționale, YOLOv8, transfer learning, localizare

I. INTRODUCERE

Fracturile osoase sunt una dintre cele mai frecvente leziuni traumatice tratate în urgențele medicale. Diagnosticul se bazează în principal pe analiza radiografiilor, un proces la care pot apărea erori de interpretare. Automatizarea acestui proces prin tehnici de deep learning poate reduce semnificativ timpul de diagnostic și rata erorilor.

Rețelele neuronale convoluționale au demonstrat că pot concura cu experții umani în sarcini bine definite de clasificare și detecție a imaginilor medicale. Acest proiect testează cât de bine o arhitectură de tip one-stage detector poate localiza și clasifica fracturi în radiografii.

Contribuțiile principale ale lucrării sunt:

- antrenarea modelului YOLOv8s pentru detecția a șapte clase de fracturi și leziuni ale membrului superior;
- evaluarea cantitativă a performanței prin metrici standard (mAP, Precision, Recall) și analiza curbelor de antrenament;
- interpretarea rezultatelor prin matricea de confuzie;
- dezvoltarea unei aplicații web interactive pentru testarea modelului în timp real.

II. LUCRĂRI CONEXE ȘI ALEGEREA MODELULUI

Detecția automată a fracturilor osoase îmbină metode de clasificare globală și de detecție cu localizare.

Detectoarele de tip one-stage, în special familia YOLO, prezintă avantajul că produc simultan eticheta clasei și bounding box-ul obiectului detectat, într-o singură trecere prin rețea.

Am ales YOLOv8s (Small) pentru acest proiect fiindcă oferă echilibru între capacitatea de reprezentare și eficiența computațională.

III. SETUL DE DATE

Setul de date utilizat este *Bone Fracture Detection — Computer Vision Project*, disponibil public pe Kaggle. Acesta conține radiografii ale membrului superior adnotate în format YOLO împărțite în trei categorii: *train*, *valid* și *test*. Setul acoperă șapte clase de fracturi și leziuni:

- **Elbow positive** — radiografii ale cotului cu leziuni vizibile.
- **Fingers positive** — fracturi la nivelul degetelor.
- **Forearm fracture** — fracturi ale antebrățului (radius și/sau ulnă).
- **Humerus fracture** — fracturi ale humerusului.
- **Humerus** — radiografii ale humerusului fără fractură explicită, distincte de clasa *humerus fracture*.
- **Shoulder fracture** — fracturi la nivelul umărului.
- **Wrist positive** — leziuni la nivelul încheieturii mâinii.

Distribuția claselor este dezechilibrată: clasele *forearm fracture* și *humerus* sunt mai bine reprezentate, în timp ce *wrist positive* și *elbow positive* au un număr mai redus de exemple. Acest dezechilibru influențează direct performanța modelului, după cum se observă în analiza matricei de confuzie (Secțiunea V-C).

IV. METODOLOGIE

A. Preprocesarea Datelor

Imaginile sunt redimensionate la 640×640 pixeli, rezoluția de intrare așteptată de modelul YOLOv8s. Încărcarea setului de date se realizează prin configurarea unui fișier YAML care specifică căile către partițiile de antrenament, validare și test, numărul de clase (7) și numele acestora.

B. Augmentarea Datelor

Pentru a îmbunătăți modelul au fost aplicate următoarele augmentări în timpul antrenamentului:

- variații de culoare în spațiul HSV: *hue* (± 0.015), *saturation* ($\times 0.7$), *value* ($\times 0.4$);
- flip orizontal cu probabilitate 0.5 și flip vertical cu probabilitate 0.1;
- mozaic (*mosaic*) cu probabilitate 1.0, care combină patru imagini într-una singură pentru a diversifica contextul obiectelor.

C. Arhitectura Rețelei

Modelul utilizat este YOLOv8s (Small). Arhitectura integrează un backbone bazat pe blocuri C2f (Cross Stage Partial cu două convoluții), un neck de tip PAN (Path Aggregation Network) pentru agregarea caracteristicilor la scări multiple și un cap de detecție decuplat pentru clasificare și regresie. Capul original de detecție a fost reconfigurat pentru șapte clase în locul celor 80 din COCO.

D. Procedura de Antrenament

Modelul a fost inițializat cu greutatele pre-antrenate pe setul COCO (yolov8s.pt) și adaptat pe setul de date. Configurația de antrenament este prezentată în Tabelul I.

Tabela I
CONFIGURAȚIA ANTRENAMENTULUI

Parametru	Valoare
Epoci	20
Rezoluție imagini	640×640
Batch size	16
Optimizer	AdamW
Learning rate inițial	0.001
Learning rate final	0.01 (factor relativ)
Weight decay	0.0005
Patience (early stop)	15

Pentru inferență s-au utilizat un prag de confidență de 0.25 și un prag IoU de 0.45 pentru Non-Maximum Suppression (NMS).

V. REZULTATE

A. Performanța Globală

Performanța modelului a fost evaluată pe setul de validare utilizând metricile standard pentru detecția obiectelor. Tabelul II prezintă valorile obținute după 20 de epoci de antrenament.

Tabela II
PERFORMANȚA MODELULUI YOLOv8s PE SETUL DE VALIDARE

Metrică	Valoare
Precision	0.249
Recall	0.327
mAP@0.5	0.266
mAP@0.5:0.95	0.103

B. Dinamica Antrenamentului

Figura 1 prezintă evoluția principalelor metrici pe parcursul celor 20 de epoci.

Funcția de pierdere (*Box Loss*) scade constant pentru setul de antrenament, sugerând că modelul învață pe parcurs să găsească mai precis obiectele. Pierdere pe setul de validare se stabilizează după primele epoci. Asta arată că modelul poate generaliza fără a supraînvăța.

În primele epoci precizia fluctuează, apoi se stabilizează treptat, în timp ce recall-ul crește constant pe parcursul antrenamentului. Metrica mAP@0.5 crește continuu de-a lungul celor 20 de epoci. Creșterea constantă a mAP arată

că performanța modelului ar mai putea fi îmbunătățită prin continuarea antrenamentului.

C. Analiza Matricei de Confuzie

Figura 2 prezintă matricea de confuzie obținută pe setul de validare.

Cea mai bună performanță a modelului este pentru clasele *forearm fracture* și *humerus*, care sunt și cele mai bine reprezentate în setul de antrenament. Din cauza asemănării vizuale ridicate cu clasa *humerus*, clasa *humerus fracture* nu prezintă detecții corecte,

Există situații în care modelul nu detectează fractura prezentă, în imagine pentru mai multe clase, fals negativ. Matricea confirmă că performanța este direct proporțională cu numărul de exemple disponibile per clasă.

D. Discuție

Valoarea recall-ului (0.327) superioară preciziei (0.249) arată faptul că modelul detectează mai multe obiecte chiar dacă apar false pozitive. Principalii factori care limitează performanța sunt dezechilibrul distribuției claselor și numărul relativ mic de epoci de antrenament. Modelul nu a atins convergența completă, încă se mai poate îmbunătăți.

VI. APLICAȚIE WEB

Am dezvoltat o interfață web folosind Streamlit pentru a putea testa în mod interactiv modelul. Utilizatorul încarcă o radiografie, iar aplicația aplică preprocesările utilizate la antrenament (640×640 , normalizare), rulează modelul și afișează detecțiile suprapuse pe imagine împreună cu clasa și scorul. Aplicația are ca scop evaluarea rapidă a modelului pe date noi, fără ca utilizatorul să aibă cunoștințe tehnice.

VII. CONCLUZII

Această lucrare prezintă un sistem automat de detecție a fracturilor osoase bazat pe YOLOv8s, antrenat pe radiografii adnotate pentru șapte clase. Modelul obține un scor mAP@0.5 de 0.266, o precizie de 0.249 și un recall de 0.327 după 20 de epoci. Astfel, detecția obiectelor prin tehnici de deep learning poate contribui semnificativ în imagistica medicală.

Dezavantajul principal este numărul redus de exemple pentru unele clase. Performanța sistemului poate fi îmbunătățită prin mărirea setului de date, tehnici suplimentare de augmentare și utilizarea unor variante mai complexe din familia YOLOv8 (YOLOv8m, YOLOv8l).

BIBLIOGRAFIE

- [1] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLOv8," *GitHub*, 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics>
- [2] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," *Proc. IEEE CVPR*, 2016.
- [3] P. Rajpurkar et al., "Deep learning for chest radiograph diagnosis," *PLOS Medicine*, vol. 15, no. 11, 2018.



Figura 1. Evoluția metricilor de antrenament: Box Loss, Precision, Recall, mAP@0.5 și mAP@0.5:0.95.




Figura 2. Matricea de confuzie pentru modelul YOLOv8s pe setul de validare.